

Evaluación de parámetros en la detección de anomalías cardiacas mediante electrocardiogramas y red neuronal convolucional

Angela M. Aguirre¹

¹Instituto de Física, Universidad de Antioquia U de A, calle 70 No. 52-21, Medellín, Colombia
e-mail address: angela.aguirrea@udea.edu.co

In this project a CNN was trained multiple times with electrocardiograms and different features from the ECGs to analyze which dataset for training gave the best results in accuracy, loss, and false predictions; so that the neural network may potentially be used in clinical decision making and finally help a good health outcome of the patient. The obtained results are very promising, with high accuracy, low loss in training, and good performance prediction on data not used in training.

Palabras clave: Electrocardiograma (ECG), Arritmias cardiacas, Machine Learning, Comparación, Parámetros, Red neuronal convolucional (CNN), Transformada rápida de Fourier (FFT)

I. INTRODUCCIÓN

El electrocardiograma (ECG por sus siglas en inglés) es un examen que permite visualizar una gran cantidad de información diagnóstica sobre el funcionamiento del corazón. Es una técnica no invasiva, sencilla y de bajo costo que permite guiar a médicos especialistas en la toma de decisiones que afectarán la salud del paciente [1].

Los ECG permiten identificar arritmias cardiacas, las cuales comúnmente van acompañadas de enfermedades que pueden llegar a poner en riesgo la vida, como es el caso de latidos ectópicos supraventriculares [2], los cuales pueden derivar en una fibrilación atrial y posteriormente aumentar el riesgo de un ataque cardiaco. En Estados Unidos mueren aproximadamente 300 000 personas al año por esta causa, en Francia 60 000 personas [1], y en Colombia fue la primera causa de muerte en el año 2019 [3]. Es por esto que se han concentrado esfuerzos en la detección temprana de arritmias para hacer una intervención oportuna y temprana [1], entre ellos la realización de redes neuronales para la clasificación de arritmias en electrocardiogramas [1,4]

En este proyecto se realizó el análisis del rendimiento de una red neuronal convolucional (CNN por sus siglas en inglés) entrenada con electrocardiogramas tomados de la base de datos MIT-BIH Arrhythmia en PhysioNet [5]. También se entrenó la red 3 veces más con parámetros diferentes: el área bajo la curva de la transformada rápida de Fourier (FFT por sus siglas en inglés), el área bajo la curva que presenta el latido, y la amplitud máxima del latido; con el objetivo de analizar en cuál de los 4 casos la red neuronal tenía un mejor desempeño al predecir, y analizar si es posible su uso en el ámbito de la medicina para agilizar la detección y el tratamiento de anomalías reflejadas en los ECG. Las clases a clasificar son: latidos normales, latidos ectópicos supraventriculares, latidos ectópicos ventriculares, latidos de fusión y latidos desconocidos; donde algunas de estas condiciones pueden tener una prognosis adversa en la vida de la persona [2,6,7].

II. MATERIALES Y MÉTODOS

Con base en el algoritmo desarrollado por el usuario Gregoire DC en Kaggle [8], y los datasets utilizados en el mismo, los cuales originalmente fueron tomados de la base de datos de MIT-BIH Arrhythmia, se realizó un notebook en la plataforma Colab con el cual se entrenó una red neuronal convolucional (CNN) unidimensional, la cuál se describe en detalle en la figura 1.




FIG 1. Diagrama de la red neuronal convolucional implementada

Cada tipo de latido tenía una clasificación asociada a un número para su ingreso a la red neuronal. Los tipos de latidos a clasificar son: latidos normales N (clase 0), latidos ectópicos supraventriculares -S (clase 1), latidos ectópicos ventriculares -V (clase 2), latidos de fusión -F (clase 3) y latido desconocido -Q (clase 4). Los dataset para entrenamiento de la red neuronal contenían (en orden descendente): 72471 datos de latidos normales, 6431 de latidos desconocidos, 5788 de latidos ectópicos ventriculares, 2223 de latidos ectópicos supraventriculares y 641 de latidos de fusión. Antes de ingresar los datos a la red, se realizó un remuestreo aleatorio de los datos con la función resample de la librería sklearn.utils, con el fin de que cada clase tuviera 20000 datos para entrenamiento.

Seguidamente, se realizó el entrenamiento del modelo con el dataset obtenido. Luego, con ayuda del análisis de las señales hecho en el notebook de Kaggle, se aisló el

rango de los datos en dónde se observa la porción del segmento ST y la onda T de los latidos (FIG 2), ya que estos representan parte de la duración de la recuperación ventricular, lo que los hace relevantes en las condiciones a clasificar [1].




FIG 2. Representación esquemática de las inflexiones básicas presentes en electrocardiogramas

A partir de esta selección, se calcularon diferentes características de los datos en la región mencionada: el área bajo la curva de la transformada rápida de Fourier (FFT por sus siglas en inglés); el área bajo la curva que presenta el latido; y la amplitud máxima del latido. Estos parámetros se agregaron por separado al dataset y se entrenó nuevamente el modelo con cada propiedad calculada.

En cada entrenamiento del modelo se calculó su precisión, la matriz de confusión, se graficó la precisión y pérdida (calculada con la función `categorical_crossentropy`) con respecto al número de ciclos, y se evaluó la red con datos nuevos que no pertenecían a los dataset de training y test. Estos datos nuevos contenían electrocardiogramas de latidos normales y de latidos ectópicos supraventriculares. Para evaluar el desempeño de la red en el último paso descrito se calculó la precisión como el porcentaje de predicciones correctas con respecto al total de predicciones [9].

III. RESULTADOS

En la tabla 1 se encuentran los datos de precisión para los modelos entrenados con los diferentes parámetros. Como se puede observar, la precisión al entrenar en todos los modelos es bastante buena, con pequeñas diferencias entre ellos. Al evaluar los modelos con datos nuevos, se notan diferencias marcadas en la precisión, y es evidente que el indicador que lleva a un mejor rendimiento del modelo es el de área bajo la curva del latido. Precisamente este modelo presenta la mejor curva en la gráfica de pérdidas vs ciclos (FIG 2), ya que de todos los modelos es el que presentó una tendencia a la baja que se mantuvo con el pasar de los ciclos. Las gráficas de los otros modelos junto con sus matrices de confusión pueden consultarse en el notebook adjunto a este informe.

Esto indica que en este modelo el error cometido por la red neuronal es el menor de todos los modelos, siendo entonces el mejor modelo para la predicción de las condiciones cardiacas tratadas [10].

	Modelo entrenado con latidos	Modelo entrenado con latidos y área bajo curva de FFT	Modelo entrenado con latidos y área bajo curva del latido	Modelo entrenado con latidos y amplitud máxima del latido
Precisión al evaluar el modelo	97.40%	97.08%	96.70%	96.59%
Precisión al predecir latidos N	70.46 %	78.13 %	95.28 %	94.83 %
Precisión al predecir latidos S	78.93 %	86.83 %	93.06 %	78.93 %

Tabla 1. Datos de precisión del modelo al entrenar y al predecir en datos nuevos




FIG 2. Comportamiento de las pérdidas en el modelo que incluyó el parámetro del área bajo la curva del latido

En la figura 3 se observa la matriz de confusión del mismo modelo, y se observa que las clases donde se tiene el mayor número de falsos positivos es en latidos ectópicos supraventriculares (S) y en latidos de fusión (F). Esto se debe a que el set original contenía el menor número de datos en la clase S, seguido por la clase F, lo que conlleva a que el modelo cometa más errores en estas dos clases.




FIG 3. Matriz de confusión del modelo que incluyó el parámetro del área bajo la curva del latido

IV. CONCLUSIONES

De los resultados obtenidos se concluye que el área bajo la curva del latido en la región del segmento ST y la onda T del electrocardiograma es el parámetro que permite una mayor precisión al predecir las clases estudiadas en una red neuronal.

Para mejorar la eficiencia del algoritmo se pueden buscar bases de datos con más muestras de las clases de latidos ectópicos supraventriculares y latidos de fusión para mejorar la clasificación de estas clases.

Al mismo tiempo, la precisión obtenida en el modelo, la pérdida presentada y el número de falsos positivos hacen que este modelo sea bastante confiable en la detección de las condiciones estudiadas en este proyecto, lo que podría permitir su uso en organizaciones médicas y permitiría la rápida detección de arritmias y posiblemente priorizar tratamientos para que sean dados al paciente de la manera más oportuna posible.

V. AGRADECIMIENTOS

Me gustaría agradecer al profesor Juan Marcos Marín por su apoyo, su asesoría en la realización de este proyecto y por contactarme con Iván y Alejandra, a quienes también agradezco su valiosa asistencia en las áreas de electrocardiografía y Machine Learning.

VI. BIBLIOGRAFÍA

[1] Gothwal, H., Kedawat, S. and Kumar, R., 2011. *Cardiac arrhythmias detection in an ECG beat signal using fast fourier transform and artificial neural network*. [online] Scirp.org. Available at: <https://www.scirp.org/pdf/JBiSE20110400007_26458484.pdf> [Accessed 10 April 2022].

[2] Tuan Le Nguyen, L., 2010. *Supraventricular Ectopic Activity: When Excessive it is not all Benign!*. [online] PubMed Central (PMC). Available at: <<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC4956355/>> [Accessed 10 April 2022].

[3] Bayer. 2020. *Las enfermedades cardiovasculares son la primera causa de muerte en Colombia y el mundo*. [online] Available at: <<https://www.bayer.com/es/co/las-enfermedades-cardiovasculares-son-la-primera-causa-de-muerte-en-colombia-y-el-mundo>> [Accessed 10 April 2022].

[4] B. V. P Prasad & Velusamy Parthasarathy (2018) *Detection and classification of cardiovascular abnormalities using FFT based multi-objective genetic algorithm*, *Biotechnology & Biotechnological Equipment*, 32:1, 183-193, DOI: 10.1080/13102818.2017.1389303 [online] tandfonline.com Available at: <<https://doi.org/10.1080/13102818.2017.1389303>> [Accessed 10 April 2022].

[5] Goldberger, A., Amaral, L., Glass, L., Hausdorff, J., Ivanov, P. C., Mark, R., ... & Stanley, H. E. (2000). PhysioBank, PhysioToolkit, and PhysioNet: Components of a new research resource for complex physiologic signals. *Circulation* [Online]. 101 (23), pp. e215–e220.

[6] London Heart Clinic. n.d. *Ectopic Heartbeat Treatment | Ventricular Ectopics | London Heart Clinic*. [online] Available at: <<https://theheartclinic.london/conditions-treatment/ventricular-ectopics-treatment/>> [Accessed 10 April 2022].

[7] L. MARRIOTT, M.D., H., SCHWARTZ, M.B., M.R.C.P., N. and Bix, M.D., H., 1962. *Ventricular Fusion Beats*. [online] Ahajournals.org. Available at: <<https://www.ahajournals.org/doi/pdf/10.1161/01.CIR.26.5.880>> [Accessed 10 April 2022].

[8] DC, G., 2021. *Arrhythmia on ECG Classification using CNN*. [online] Kaggle.com. Available at: <<https://www.kaggle.com/code/gregoiredc/arrhythmia-on-ecg-classification-using-cnn>> [Accessed 10 April 2022].

[9] Barkved, K., 2022. *How To Know if Your Machine Learning Model Has Good Performance | Obviously AI*. [online] Obviously.ai. Available at: <<https://www.obviously.ai/post/machine-learning-model-performance>> [Accessed 10 April 2022].

[10] Google Developers. 2022. *Descending into ML: Training and Loss | Machine Learning Crash Course | Google Developers*. [online] Available at: <https://developers.google.com/machine-learning/crash-course/descending-into-ml/training-and-loss?hl=es_419> [Accessed 10 April 2022].